

Benchmarking de modelos de inteligencia artificial y extracción de características para la detección de fatiga isquiotibial con aplicaciones deportivas

Panez R.¹, Llanos D.¹, Garcia S.¹

¹Universidad Peruana Cayetano Heredia

Introducción

Músculos afectados en deportistas por lesiones [1]



1142

desgarros de isquiotibiales durante el periodo 2009-2014 [2]

Problemática

La incidencia de lesiones musculares en el músculo isquiotibial en jóvenes deportistas refleja la ausencia de herramientas precisas para la detección de la fatiga, lo que dificulta la aplicación de estrategias y tecnologías eficaces de monitoreo y control para el óptimo rendimiento deportivo.

Objetivo principal

Obtener, a partir del diseño de un benchmark, la mejor combinación de features, modelo de IA y parámetros de entrenamiento para desarrollar nuevos dispositivos dirigidos a detección de fatiga muscular en deportistas profesionales



Materiales y métodos

Selección de database y señal

"Surface electromyographic signals collected during long-lasting ground walking of young able-bodied subjects" [3]




- 31 señales con 2 canales
- Muestreo a 2000Hz con 12 bits

Filtrado y preprocesamiento

Pasabanda → **Notch**

- Banda entre 20 y 450 Hz
- Orden 4
- Elimina 60Hz
- Q = 30



ICA → **Normalización**

- Remoción artefactos
- Valores entre 0 y 1

Extracción de características

- Set 1: MPF y RMS
- Set 2: iEMG y MDF
- Set 3: Wavelets y VAR
 - Familia db4
 - Nivel 4

Entrenamiento para modelos de inteligencia artificial

Modelos utilizados

- SVM
- KNN
- Nearest centroid

Parámetros training-validation-testing

- Tres distribuciones:
 - 80-10-10
 - 70-15-15
 - 60-20-20

Pseudo-etiquetas descriptivas

- No Fatiga = 0
- Fatiga = 1

Se aplicará cada condición, cada modelo y set; luego, se comparará el de mejor precisión


Se eligieron los modelos y parámetros de acuerdo a lo más utilizado en detección de fatiga en señales EMG y algoritmos comunes para su clasificación [4-6].

Librerías utilizadas:

- Scikit-learn
- Numpy
- Pandas
- Matplotlib
- Seaborn
- SciPy
- PyWavelets


Resultados

Set 1: MPF y RMS




• Mejor distribución: 80-10-10

Set 2: iEMG y MDF



• Mejor distribución: 60-20-20

Set 3: Wavelets y VAR



• Mejor distribución: 80-10-10

Conclusiones

- El tipo de feature utilizado es el factor dominante en el rendimiento de la detección de fatiga muscular.
- **Set 2** fue la representación más estable y coherente con la literatura sobre fatiga muscular.
- **Set 3** capturó buena información tiempo-frecuencia, pero su mejora no fue consistente.
- **Set 1** actuó como baseline y mostró el menor desempeño, indicando poca capacidad discriminativa.

Datos de contacto

Rafael Alonso Panez Cuzano

rafael.panez@upch.pe

949 494 270

Dhiego Llanos Gustavo Florián

dhiego.llanos@upch.pe

975 712 065

957 362 306

Referencias bibliográficas

- [1] Ekstrand, M. Hägglund y M. Waldén, "Epidemiology of Muscle Injuries in Professional Football (Soccer)", Amer. J. Sports Medicine, vol. 39, n.º 6, pp. 1226–1232, febrero de 2011. Accedido el 19 de octubre de 2025. [En línea]. Disponible: <https://doi.org/10.1177/0363546510395879>
- [2] S. L. Dalton, Z. Y. Kerr y T. P. Dompter, "Epidemiology of Hamstring Strains in 25 NCAA Sports in the 2009-2010 to 2013-2014 Academic Years", Amer. J. Sports Medicine, vol. 43, n.º 11, pp. 2671-2679, septiembre de 2015. Accedido el 19 de octubre de 2025. [En línea]. Disponible: <https://doi.org/10.1177/0363546515599631>
- [3] "Surface electromyographic signals collected during long-lasting ground walking of young able-bodied subjects". PhysioNet. Accedido el 19 de octubre de 2025. [En línea]. Disponible: <https://physionet.org/content/semg/1.0.1/>
- [4] M. González-Izal, A. Malanda, E. Gorostiaga y M. Izquierdo, "Electromyographic models to assess muscle fatigue", J. Electromogr. Kinesiol., vol. 22, n.º 4, pp. 501-512, agosto de 2012. Accedido el 2 de diciembre de 2025. [En línea]. Disponible: <https://doi.org/10.1016/j.jelekin.2012.02.019>
- [5] S. M. Sid'El Moctar, I. Rida y S. Boudaoud, "Comprehensive Review of Feature Extraction Techniques for sEMG Signal Classification: From Handcrafted Features to Deep Learning Approaches", IRBM, p. 100866, noviembre de 2024. Accedido el 2 de diciembre de 2025. [En línea]. Disponible: <https://doi.org/10.1016/j.irbm.2024.100866>
- [6] M. Sharizadeh, E. H. Hafshejani, C. J. Mitchell, M. Chiao y D. Grecov, "Predicting muscle fatigue during dynamic contractions using wavelet analysis of surface electromyography signal", Biocybern. Biomed. Eng., abril de 2023. Accedido el 2 de diciembre de 2025. [En línea]. Disponible: <https://doi.org/10.1016/j.bbe.2023.04.002>